

Повышение качества Multi-Label классификации эмоций в русскоязычных текстах с использованием легковесных трансформеров

Improving the Quality of Multi-Label Emotion Classification in Russian Texts Using Lightweight Transformers

Ярослав Баймлер

Май 2026

Аннотация

В работе рассматривается задача автоматической классификации эмоций в коротких русскоязычных сообщениях неформального интернет-дискурса. Эксперименты проведены на открытой части датасета AIST (50 750 сообщений), размеченной по пяти эмоциональным категориям: нейтральность, радость, грусть, злость, неуверенность. Воспроизведён базовый подход на основе fastText-векторов Common Crawl и логистической регрессии (Macro F1 = 0.716). Исследован ряд улучшений: добавление частеречных признаков, градиентный бустинг (CatBoost), стекинг статических эмбеддингов, а также тонкая настройка (fine-tuning) предобученного трансформера ruBERT-tiny2. Наилучший результат достигнут дообучением трансформера — Macro F1 = 0.8348, что на 11.9 процентных пунктов выше воспроизведённого baseline и превосходит лучший опубликованный результат для полного датасета (0.81). Показано, что легковесные трансформеры способны значительно улучшить качество распознавания эмоций даже при ограниченных вычислительных ресурсах и неполном объёме данных. Проведён анализ ошибок и абляционное сравнение моделей, выявившее, что основной прирост достигается на наиболее трудных классах (нейтральность и радость). Практическая значимость работы заключается в демонстрации эффективности современных языковых моделей для анализа эмоциональной окраски русскоязычной интернет-коммуникации.

1. ВВЕДЕНИЕ

Автоматическое распознавание эмоций в тексте (emotion detection) — актуальная задача обработки естественного языка, востребованная в системах мониторинга социальных сетей, диалоговых агентах и анализе обратной связи. Для русского языка существует несколько публичных датасетов, в том числе AIST, содержащий короткие сообщения из Telegram и VK, размеченные по пяти эмоциональным классам: нейтральность, радость, грусть, злость, неуверенность.

Цели настоящей работы:

- Воспроизвести baseline, описанный в статье Babii et al. (2021), на доступной части датасета AIST и доступных fastText векторах;
- Исследовать, способны ли нелинейные методы (градиентный бустинг) и лёгкие трансформеры улучшить качество классификации;
- Провести анализ ошибок и вклад различных компонентов модели.

1.1 Команда

Ярослав Баймлер - постановка задачи, EDA, обучение моделей и проведение экспериментов, подготовка отчета

2. ОБЗОР ЛИТЕРАТУРЫ

Базовыми для задачи являются работы Babii et al. (2020) и Babii et al. (2021). В первой предложен гибридный подход: TF IDF + логистическая регрессия с лингвистическими признаками, достигнуто Macro F1 = 0.718. Во второй TF IDF заменён на fastText векторы, обученные на Twitter (DeepPavlov), что повысило результат до Macro F1 = 0.81. Авторы также установили, что функциональные слова критичны для задачи (их удаление снижает F1 на 10%), а простые нейросети (CNN, LSTM, GRU) уступают комбинации fastText+LogReg.

Дополнительные методологически близкие работы:

Sboev et al. (2021) — создание датасета CEDR и применение BiLSTM+ELMo для русского языка.

Demszky et al. (2020) — fine tuning BERT на английском GoEmotions, демонстрирующий эффективность трансформеров для многоклассовой классификации эмоций.

Plaza del Arco et al. (2021) — комбинация BERT с BiLSTM, подтверждающая пользу нелинейных классификаторов поверх эмбедингов.

Kazyulina et al. (2021) — анализ инженерии признаков для русского языка, включая морфологические и стилистические маркеры.

Наш обзор опирается на перечисленные источники и обосновывает выбор стратегии экспериментов.

3. ОПИСАНИЕ МОДЕЛЕЙ

В работе последовательно применялись и сравнивались три семейства моделей:

3.1. Линейные модели на статических эмбедингах

fastText + Logistic Regression (baseline): Векторы предложений получаются усреднением предобученных fastText векторов слов (Common Crawl, 300d). Классификатор — логистическая регрессия с L2 регуляризацией ($C=20$), обучаемая кросс энтропийной функцией потерь. Модель служит точкой отсчёта, воспроизводя подход статьи 2021 г.

fastText + POS + Logistic Regression: К усреднённому fastText вектору конкатенируется 15 мерный вектор долей частей речи, полученных с помощью библиотеки spaCy. Ожидается, что POS признаки явно кодируют информацию о функциональных словах, важность которых доказана в литературе.

3.2. Градиентный бустинг

CatBoost на fastText+POS: Градиентный бустинг над деревьями решений, автоматически балансирующий классы (`auto_class_weights='Balanced'`). Используются те же fastText и POS признаки. Модель способна улавливать нелинейные взаимодействия и отбирать наиболее информативные признаки.

CatBoost стек (Common Crawl + POS + AIST fastText): К базовым признакам добавляется 100 мерный fastText вектор, обученный непосредственно на корпусе AIST (skip gram, 10 эпох). Такой стек объединяет общезыковую семантику Common Crawl, грамматическую информацию POS и специфичную лексику интернет-дискурса.

CatBoost + замороженные BERT эмбединги: В дополнение к fastText+POS подаются 312 мерные векторы, извлечённые из предобученного rubert-tiny2 (усреднение скрытых состояний последнего слоя). Гипотеза состояла в обогащении признаков контекстной семантикой, однако модель показала ухудшение качества.

3.3. Трансформерные модели

Fine tuned rubert tiny2: Лёгкий русскоязычный BERT (29 млн параметров) дообучается на задаче классификации эмоций в течение 5 эпох с оптимизатором AdamW ($lr=2e-5$) и косинусным планировщиком. Это основной кандидат, способный адаптироваться к стилю коротких неформальных сообщений.

Ансамбль BERT + CatBoost: Вероятности fine tuned трансформера и CatBoost стека усредняются арифметически. Предполагалось, что разнородные модели могут компенсировать ошибки друг друга, однако на практике ансамбль не превзошёл чистый трансформер.

4. ДАННЫЕ

Датасет AIST представлен в открытом доступе (файл train_data.csv, 50 750 записей). Каждое сообщение содержит исходный текст (text), метку эмоции (ton: 0 – neutral, 1 – joy, 2 – sadness, 3 – anger, 4 – uncertainty) и нормализованную версию (analysis). Классы близки к сбалансированным: от 9 379 (neutral) до 10 749 (uncertainty).

В ходе предварительного анализа установлено:

Средняя длина сообщения — 4–5 слов, медиана — 4 слова, что типично для неформальной интернет-коммуникации.

Наиболее частотные слова каждого класса соответствуют ожидаемой эмоциональной окраске (например, «блин», «убить» для anger; «хороший», «люблю» для joy).

Удаление пунктуации и цифр при очистке текстов не искажает эмоциональную составляющую.

Пропуски и дубликаты отсутствуют.

5. ЭКСПЕРИМЕНТЫ

5.1. Метрики

Основной метрикой качества выбрана Macro F1, как и в оригинальной работе Babii et al. (2021). Для каждого класса c вычисляются точность P_c и полнота R_c , затем $F1_c = 2 * \frac{P_c * R_c}{P_c + R_c}$. Итоговая Macro F1 равна среднему арифметическому $F1_c$ по всем C классам:

$$\text{Macro F1} = \frac{1}{C} \sum_{c=1}^C F1_c$$

Такая метрика равнозначно учитывает все классы, что важно при небольшом дисбалансе данных.

5.2. Установка эксперимента

Все эксперименты проводились на едином стратифицированном разбиении 80/20 (random_state=42), чтобы обеспечить одинаковое распределение классов в обучающей и тестовой выборках. Тексты предварительно очищались: удалялись пунктуация, цифры, схлопывались повторяющиеся символы (более двух подряд).

Общие гиперпараметры:

Для логистической регрессии: $C=20$, $\text{solver}='lbfgs'$, $\text{max_iter}=100\,000$.

Для CatBoost: глубина 6, $\text{learning_rate}=0.1$, $\text{early_stopping_rounds}=50$, $\text{auto_class_weights}='Balanced'$.

Для fine tuning rubert-tiny2: оптимизатор AdamW ($\text{lr}=2e-5$), косинусный планировщик, $\text{batch_size}=32$, 5 эпох.

Все эксперименты, если не указано иное, выполнялись в одном прогоне.

5.3. Базовые модели

В качестве отправной точки был воспроизведён подход из статьи 2021 года: усреднённые fastText векторы Common Crawl 300d + логистическая регрессия. Этот baseline показал Macro F1 = 0.7162, что несколько ниже заявленных 0.81 из за использования половины датасета и другой модели эмбедингов (Common Crawl вместо DeepPavlov Twitter). Дополнительно были проверены варианты с балансировкой классов ($\text{class_weight}='balanced'$, 0.7157) и с калибровкой порогов (0.7256). Простейший TF IDF + LogReg, описанный в Babii et al. (2020), не воспроизводился, так как заведомо слабее.

6. Результаты

Итоговые значения Macro F1 для всех моделей представлены в таблице.

Модель	Macro F1
fastText CC + LogReg (baseline)	0.7162
fastText CC + LogReg + balanced	0.7157
fastText CC + POS + LogReg	0.7257
fastText CC + POS + LogReg + пороги	0.7256
CatBoost (fastText+POS)	0.7737
CatBoost + fastText+POS+rubert	0.7660
CatBoost стек (CC+POS+AIST)	0.7774
rubert-tiny2 fine-tuned	0.8348
BERT + CatBoost ансамбль	0.8348

Описание ключевых результатов:

Добавление POS-признаков к baseline дало скромный прирост (+0.95 п.п.), что согласуется с выводом авторов о важности функциональных слов.

Градиентный бустинг (CatBoost) существенно улучшил качество (+5.5 п.п. относительно baseline), а стекинг с AIST fastText позволил достичь 0.7774. Это

демонстрирует, что нелинейные модели могут эффективно комбинировать разнородные эмбединги.

Замороженные эмбединги rubert-tiny2 в CatBoost не улучшили, а ухудшили результат (0.7660). Вероятно, большая размерность и иная природа контекстных векторов внесла шум в признаковое пространство.

Тонкая настройка rubert-tiny2 привела к наилучшему результату Macro F1 = 0.8348 (+11.9 п.п. к baseline, +2.5 п.п. к литературному максимуму). Трансформер смог адаптироваться к стилю коротких сообщений, особенно улучшив распознавание ранее проблемных классов neutral (с 0.68 до 0.80) и joy (с 0.71 до 0.83) согласно анализу.

Ансамбль BERT + CatBoost не дал дополнительного выигрыша: более слабая модель не добавляет значимой информации к уже высокоуверенным предсказаниям трансформера.

Анализ ошибок лучшей модели показал, что основные ошибки возникает между neutral и anger (~5% случаев), а также между joy и uncertainty (~3%). Детальный разбор примеров приведён в сопровождающем ноутбуке.

7. ВЫВОДЫ

Лучшая модель — fine tuned rubert-tiny2 — достигла Macro F1 = 0.8348, превзойдя опубликованный результат оригинальной статьи (0.81) и baseline (0.716).

CatBoost на стеке эмбедингов (0.7774) является сильной альтернативой при невозможности использовать трансформеры.

POS-признаки и стекинг с AIST fastText полезны для бустинга, но неэффективны для линейных моделей.

Взвешивание классов, калибровка порогов и добавление замороженных эмбедингов в CatBoost не дали улучшения.

Анализ показал, что основные трудности классификации связаны с классами neutral и joy, и именно на них трансформер дал максимальный прирост.

Дальнейшие улучшения могут быть связаны с аугментацией данных для путающихся пар и дистилляцией моделей.

Список литературы

- Babii A. S., Kazyulina M. S., Malafeev A. Yu. Automatic emotion identification in Russian text messages // Computational Linguistics and Intellectual Technologies: Proceedings of the International Conference "Dialogue 2020". – 2020. – pp. 1002–1010.
- Babii A., Kazyulina M., Malafeev A. fastText-based methods for Emotion Identification in Russian Internet Discourse // Proceedings of the 13th ACM Web Science Conference (WebSci'21). – 2021. – pp. 112–119.
- Sboev A. et al. Corpus for Emotions Detecting in Russian-language Text Sentences of Different Social Sources (CEDR) // Procedia Computer Science. – 2021. – Vol. 190. – pp. 442–447.
- Demszky D. et al. GoEmotions: A Dataset of Fine-Grained Emotions // Proceedings of ACL 2020. – pp. 4040–4054.
- Plaza del Arco F. M. et al. Leveraging pre-trained language models for emotion classification // Procesamiento del Lenguaje Natural. – 2021. – Vol. 67. – pp. 73–80.